

# Predviđanje bolesti srca algoritmima strojnog učenja

Lucija Dumančić

Lipanj 2024

## Sažetak

Kardiovaskularne bolesti i stopa smrtnosti uzrokovana istim čine značajan udio ukupne smrtnosti u svijetu. Čimbenici koji uzrokuju bolesti srca su brojni te se iz tog razloga dulji niz godina prikupljaju podaci o simptomima te se stvaraju baze podataka. Strojno učenje se koristi za poboljšanje učinkovitosti ranog otkrivanja bolesti i poboljšanje učinkovitosti liječenja. U ovom radu je korišten skup podataka sa 12 značajki na koji su primijenjeni logistička regresija i konvolucijska neuronska mreža te evaluirani "Accuracy" i "F1 Score" metrikama. Model konvolucijske neuronske mreže pokazao je bolje performanse.

## 1 Uvod

Prema World Health Organization [18] kardiovaskularne bolesti glavni su uzrok smrti u svijetu, a procjenjuje se da odnose 17,9 milijuna života svake godine, što čini 32% svih smrtnih slučajeva u svijetu. Uzroci oboljevanja su višestruki, a posebno je nužno naznačiti problem koji se javlja njihovom kombinacijom. Iako se razlikuju genetski i bihevioralni čimbenici u razvoju oboljenja, posebnu pažnju treba posvetiti bihevioralnim čimbenicima rizika razvoja srčanih bolesti. Prije svega, to su: nezdrava prehrana, nedostatna tjelesna aktivnost, pušenje i prekomjerna uporaba alkohola. Učinci bihevioralnih čimbenika rizika mogu se manifestirati kod pojedinaца kao povišen krvni tlak, povišen šećer u krvi, povišeni lipidi u krvi te prekomjerna tjelesna težina i pretilost [18]. Kako bi se moglo preventivno djelovati, kod osoba s kardiovaskularnim rizikom nužno je što ranije otkrivanje i upravljanje ponašanjem, odnosno nužno je postaviti pravovremenu i točnu dijagnozu koja je ključna za učinkovito liječenje. Kada bi se određeni uzroci pojavnosti bolesti poduprti ponašanjem ili parametri dobiveni medicinskom dijagnostikom otkrili na vrijeme, brojna patološka stanja ili eventualna smrt bi se mogli spriječiti ili značajno umanjiti. Iz tog razloga dulji niz godina prikupljani su podaci o različitim uzročnicima ili simp-

tomima bolesti te su isti pohranjivani u baze podataka. Ideja izrade ovakvih baza podataka je stvaranje baze znanja koja će omogućiti izradu automatiziranog sustava koji će procijeniti rizik nastanka kardiovaskularnih bolesti na temelju medicinskih parametara pacijenta [16]. Za stvaranje takvih, automatiziranih sustava za procjenu rizika oboljenja, koriste se algoritmi strojnog učenja. Algoritmi strojnog učenja za svoj rad trebaju veliku količinu podataka koji se koriste u fazi uvježbavanja sustava, a omogućuje stvaranje modela koji temeljem prethodnog znanja može predvidjeti izlaz iz modela za novi ulaz. To znači kako nije potrebno imati na raspolaganju podatke o svim mogućim kombinacijama čimbenika koji djeluju na pojavnost oboljenja, već je dovoljno imati veliku količinu podataka iz kojih će algoritam pronaći vezu koja se tada ugrađuje u konačni model strojnog učenja. Iz navedenih se razloga strojno učenje sve više koristi u različite svrhe pa tako i za predviđanje srčanih bolesti, upravo zbog sposobnosti analize velikih skupova podataka i identificiranja obrazaca koji se ne mogu lako otkriti tradicionalnim statističkim metodama.

Predviđanje razvoja srčanih bolesti ključan je zadatak u medicinskom području, gdje točni i interpretirajući modeli mogu značajno utjecati na ishode pacijenata i strategije liječenja. Modeli strojnog učenja koji su korišteni u ovom radu su logistička regresija

(LR) i konvolucijska neuronska mreža (CNN). Integracija LIME i SHAP grafikona u analizi ne samo da pomaže u interpretaciji predikcija, već gradi transparentnost u implementaciji ovih modela u kliničkim postavkama. Vizualizacijom kako različite značajke doprinose predikciji, ovi alati pomažu u razumijevanju i validaciji predikcija modela, što na kraju dovodi do bolje informiranih medicinskih odluka.

## 2 Pregled istraženosti područja

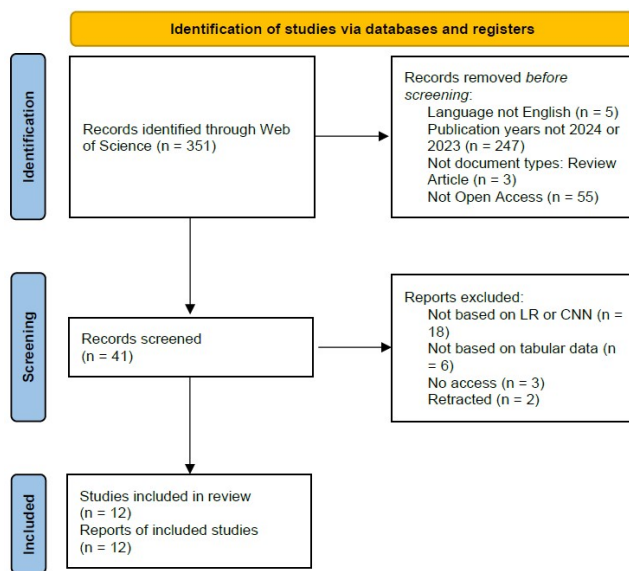
Cilj pregleda istraženosti područja je identificirati znanstvene radove koji koriste tehnike strojnoga učenja za predviđanje bolesti srca. Kako bi se odabrali relevantni radovi koristi se citatna baza Web of science (WoS) u kojoj su pohranjeni recenzirani znanstveni radovi i koja prati citiranost pojedinih radova. Navedena citatna baza ima i programsku podršku koja omogućuje jednostavno pretraživanje baze znanstvenih članaka prema različitim kriterijima. Kriteriji pretraživanja definirani su uz poštivanje specifičnih termina korištenih u području istraživanja, pa su za upit odabrani: naslov "heart disease prediction" ili naslov "heart disease classification". S početnim upitom WoS baza kao rezultat prikazuje 351 rad. Kako bi se odlučilo koji radovi su relevantni za ovo istraživanje primijenjeni su kriteriji isključivanja. U početnoj fazi identificiranja radova primijenjeni su filteri kojima su zadržani svi radovi koji zadovoljavaju sljedeće kriterije:

- Rad napisan na engleskom jeziku
- Rad objavljen 2024. ili 2023. godine
- Rad nije pregledni članak
- Rad ima otvoren pristup

Nakon ovog koraka preostao je 41 rad u fazi pretraživanja. U ovoj fazi, pregledani su naslovi i sažeci svih pronađenih radova kako bi se identificirali oni koji ispunjavaju kriterije uključivanja. Kriteriji uključivanja obuhvaćaju sljedeće radove:

- U radu je obrađena LR ili CNN
- Rad je temeljen na tabličnim podacima

Pregled istraženosti područja na kraju je rezultirao sa 12 radova u završnoj fazi koji su detaljnije obrađeni u nastavku. Detaljan proces odabira radova ilustriran je u PRISMA dijagramu toka (Slika 1).



Slika 1: PRISMA dijagram

Tablica 1 predstavlja usporedbu odabranih radova. Usporedba je napravljena uzimajući u obzir korišteni skup podataka za uvježbavanje i predviđanje, algoritme za predviđanje te točnost modela vrednovanog "Accuracy score" i "F1 score" metrikom.

## 3 Metodologija

### 3.1 Skup podataka

Model predviđanja koristi skup podataka s Kaggle-a pod nazivom "Heart Failure Prediction Dataset" [17]. Ovaj skup podataka je odabran zbog slobodnog pristupa, sadrži parametre koji se najčešće koriste i u drugim skupovima podataka ovog konteksta te nema nedostajućih podataka. Sadrži podatke o 918 pacijenata koji su opisani kroz 12 značajki. Veći dio podataka predstavlja numeričke varijable, dok su preostale varijable kategoričke. U Tablici 2 su objašnjene pojedine značajke i njihove vrijednosti. Ovaj skup

podataka stvoren je kombinacijom 5 različitih skupova podataka, a to su: Cleveland, Hungarian, Switzerland, Long Beach VA, Statlog.

### 3.2 Priprema podataka

Prije samog korištenja, podaci su analizirani i pripremljeni sukladno preporukama za provjeru i analizu podataka, izvučene su važne značajke iz skupa podataka, čime su podaci pretvoreni u informacije.

Priprema podataka podrazumijeva, takozvano, čišćenje podataka, odnosno uklanjanje ili zamjenu nedostajućih podataka. Nakon provjere, utvrđeno je kako ovaj skup podataka nema nedostajućih niti dupliciranih podataka. Kontinuirana varijabla "Age" podijeljena je u potkategorije koristeći intervale od 20 godina. Tako, varijabla koja je prvotno imala 50 različitih vrijednosti sada je transformirana u pet kategorija. Te kategorije su zatim kodirane u numeričke vrijednosti, kao što je prikazano u Tablici 3. Budući da je najmanja vrijednost godine u skupu podataka 28, a najveća 77, koriste se samo 3 kategorije. Izvlačenje obilježja ili značajki (eng. Feature Engineering) jedan je od najvažnijih koraka kod uporabe tehnika strojnog učenja. Sirove podatke pretvaramo u informacije koje algoritam strojnog učenja može koristiti. Numeričke varijable su skalirane korištenjem Min-Max pristupa koji skalira značajku na fiksni raspon od  $[0, 1]$  oduzimanjem minimalne vrijednosti značajke i zatim dijeljenjem s rasponom. Nakon normalizacije, sve varijable imaju sličan utjecaj na model, poboljšavajući stabilnost i izvedbu algoritma učenja. Provjereni su stršeci podaci (eng. outliers), te su neki od njih zamijenjeni vrijednosti medijana, a neki su zadržani u neizmijenjenom obliku jer pružaju potencijalno značajne informacije vezane uz razvoj bolesti srca. Kategorijske varijable su kodirane u numeričke vrijednosti korištenjem "label encodinga", gdje svaka jedinstvena kategorija dobiva svoj brojni identifikator. Tako, sve različite kategorije u skupu podataka bivaju predstavljene odgovarajućim brojevima, što omogućava jednostavniju analizu i obradu podataka.

Ranije odabrani algoritmi strojnog učenja primijenjeni su na pripremljene podatke te su dobiveni rezultati vrednovani spomenutim metrikama. Skup poda-

taka podijeljen je u dva dijela: skup za uvježbavanje i skup za testiranje. 70% ukupnih podataka se koristilo za uvježbavanje, dok se ostatak koristio za testiranje. Testni skup podataka se koristi za evaluaciju klasifikatora, dok se na dijelu za treniranje razvijaju modeli koji predviđaju srčane bolesti.

### 3.3 Logistička regresija

Logistička regresija je statistička metoda koja se koristi za binarne klasifikacijske zadatke, a cilj joj je modeliranje vjerojatnosti određene klase ili događaja koristeći logističku funkciju. Srž logističke regresije je logistička funkcija, poznata i kao sigmoidna funkcija, koja transformira bilo koju stvarnu ulaznu vrijednost u vrijednost između 0 i 1. Ova transformacija omogućuje da se izlaz interpretira kao vjerojatnost. Jednadžba logističke regresije je predstavljena sljedećim:

$$P(y = 1 | x) = \frac{1}{1 + e^{-z}} \quad (1)$$

gdje je

$$z = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

U ovoj jednadžbi  $P(y = 1 | x)$  označava vjerojatnost da binarna izlazna varijabla  $y$  bude jednaka 1, uz zavisnu varijablu  $x$ . Funkcija  $e^{-z}$  predstavlja logističku funkciju, koja preslikava svaku stvarnu vrijednost  $z$  u raspon  $[0, 1]$ .

### 3.4 Konvolucijska neuronska mreža (CNN)

Konvolucijske neuronske mreže (engl. Convolutional Neural Networks – CNN) predstavljaju najpoznatiji i najčešće korišteni algoritam u području dubokog učenja. Njihova glavna prednost leži u sposobnosti automatskog prepoznavanja relevantnih značajki bez potrebe za ljudskim nadzorom. CNN-ovi se široko primjenjuju u raznim područjima, uključujući računalni vid, obradu govora, prepoznavanje lica i slično. Struktura CNN-a inspirirana je neuronima u mozgu ljudi i životinja. Iako su konvolucijske neuronske mreže najčešće povezane s obradom slike, njihova arhitektura može se učinkovito primijeniti i na tablične podatke koji se sastoje

od numeričkih i kategoričkih vrijednosti organiziranih u strukturiranom formatu. Tipična konvolucijska neuronska mreža sastoji se od više konvolucijskih slojeva koji prethode slojevima sažimanja, dok su završni slojevi potpuno povezani slojevi. Ključna komponenta CNN arhitekture je konvolucijski sloj, koji se sastoji od skupa konvolucijskih filtera, poznatih kao jezgre. Ovaj sloj primjenjuje filtere na ulazne podatke kako bi izdvojio mape značajki. Sloj sažimanja smanjuje veličinu mapa značajki prethodnog sloja, zadržavajući bitne informacije. Najčešće korištena metoda sažimanja je "max pooling". Na kraju svake CNN arhitekture obično se nalazi potpuno povezani sloj koji djeluje kao klasifikator, gdje je svaki neuron povezan sa svim neuronima prethodnog sloja [3]. Za predviđanje bolesti srca korištena je jednodimenzionalna konvolucijska neuronska mreža namijenjena klasifikaciji sekvencijalnih podataka. Ulazni sloj procesira sekvencijalne podatke, nakon čega slijedi niz konvolucijskih slojeva koji izlučuje značajke iz ulaznog sloja. Svaki konvolucijski sloj je praćen slojem za sažimanje s „max-pooling“ metodom koji smanjuje prostorne dimenzije podataka dok zadržava najvažnije značajke. Nakon završnih konvolucijskih slojeva i slojeva sažimanja, izlaz se ravna u jedinstveni vektor koji se zatim prosljeđuje povezanom sloju sa sigmoidnom aktivacijskom funkcijom kako bi se generirao rezultat binarne klasifikacije. Ova struktura omogućuje mreži učenje i prepoznavanje važnih obrazaca unutar sekvencijalnih podataka. Na Slici 2 je prikazan dijagram koji predstavlja arhitekturu konvolucijske neuronske mreže koja je prethodno objašnjena.

### 3.5 Evaluacijske metrike

Modeli strojnog učenja za predviđanje bolesti srca evaluirani su metrikama "Accuracy score" i "F1 score".

Prema [10] "Accuracy" ili točnost predstavlja omjer ispravno klasificiranih primjera i ukupnog broja primjera. Postupak računanja ove evaluacijske metrike je prikazan u Jednadžbi 2.

$$Accuracy = \frac{TP + TN}{(TP + TN + FP + FN)} \quad (2)$$

Kako bi objasnili metriku "F1 score" potrebno je definirati dodatne pojmove. Tako je "Precision" ili preciznost udio pozitivnih slučajeva koji su ispravno identificirani i definira se na način kako je prikazano u Jednadžbi 3:

$$Precision = \frac{TP}{(TP + FP)} \quad (3)$$

"Recall", "Sensitivity" ili odziv označava udio stvarno pozitivnih slučajeva koji su ispravno identificirani. Računa se prema Jednadžbi 4.

$$Recall = \frac{TP}{(TP + FN)} \quad (4)$$

"F1 Score" je harmonijska sredina vrijednosti preciznosti i odziva za problem klasifikacije a način na koji se računa je prikazan u Jednadžbi 5.

$$F1score = 2 * \frac{precision * recall}{precision + recall} \quad (5)$$

Dodatna pojašnjenja parametara iz jednadžbi metrika su prikazana na Slici 3.

## 4 Rezultati

Da bi se procijenila učinkovitost modela, analizirana je njihova sposobnost predviđanja razvoja bolesti srca. Model logističke regresije postigao je točnost od 86% i „F1 Score“ od 88%. S druge strane, model konvolucijske neuronske mreže (CNN) pokazao je nešto bolje performanse s točnošću i „F1 Score“ od 87%. Ovi metrički podaci ističu efikasnost modela u predviđanju razvoja bolesti srca, pokazujući robusnu izvedbu kroz različite evaluacijske kriterije. Izvještaj o klasifikaciji modela LR nalazi se na Slici 4, a CNN modela na Slici 5. U Tablici 4 su uspoređene performanse ova dva modela prema različitim studijama. Usporedba je napravljena na temelju rezultata relevantnih radova te postignutih rezultata u ovom istraživanju.

## 5 Interpretacija modela

### 5.1 LIME

Locally Interpretable Model-Agnostic Explanations (LIME) pruža objašnjenja za pojedinačne uzorke ispitivanjem učinka promjene vrijednosti jedne značajke na ishod modela. Dizajniran je za objašnjavanje pojedinačnih predikcija bilo kojeg black-box modela strojnog učenja. [7]

LIME graf na Slici 6 pokazuje utjecaj značajki na 10. uzorku. Model predviđa 14% vjerojatnost da osoba nema srčanu bolest, a 86% vjerojatnost da je osoba oboljela. Najutjecajnije značajke koje usmjeravaju predikciju prema srčanoj bolesti su ST\_Slope, ExerciseAngina, ChestPainType. Na primjer, ST\_Slope je značajan faktor koji snažno doprinosi (+0.45) predikciji srčane bolesti. Prisutnost angine inducirane vježbanjem (ExerciseAngina) također je snažan indikator (+0.20) koji doprinosi predikciji srčane bolesti. RestingBP i Sex nemaju značajan utjecaj na predikciju za ovu instancu. S desne strane slike nalaze se odgovarajuće značajke s njihovim vrijednostima.

### 5.2 SHAP

SHapley Additive exPlanations (SHAP) okvir korišten je za interpretaciju i objašnjavanje rezultata modela. [7] Korištenjem SHAP Python biblioteke, izračunat je i vizualiziran utjecaj svake značajke u procesu predviđanja. U srži okvira nalazi se izračun SHAP vrijednosti, koje mjere doprinos značajki kako bi se poboljšala interpretabilnost modela strojnog učenja. SHAP vrijednosti pružaju uvid u to kako se predikcija modela razlikuje od osnovne vrijednosti  $E[f(x)]$  kada su vrijednosti značajki nepoznate ( $x$ ). One ukazuju na utjecaj značajki na predikciju, pokazujući smjer odnosa između značajki i ciljne varijable. SHAP vrijednost blizu 1 ili -1 označava snažan pozitivan ili negativan doprinos specifičnoj predikciji, dok vrijednost blizu 0 ukazuje na mali doprinos. Različiti grafovi generirani ovim okvirom olakšavaju razumijevanje doprinosa različitih značajki.

Na Slici 7 je prikazan SHAP vodopadni graf koji

objašnjava predikciju modela za pojedinačni slučaj. Model predviđa rezultat od 0.258 za ovaj slučaj, što je ispod prosječne predikcije (0.501), ukazujući na niži rizik od bolesti srca. Značajke koje znatno doprinose smanjenju rizika su odsutnost angine izazvane vježbanjem i činjenica da je osoba ženskog spola. Nagib ST segmenta i rezultati EKG-a su primarni faktori koji blago povećavaju rizik.

SHAP bar plot na Slici 8 sažima prosječni utjecaj svake značajke na predikcije modela. X-os prikazuje prosječnu apsolutnu SHAP vrijednost, koja predstavlja prosječni doprinos svake značajke izlazu modela, bez obzira na smjer (pozitivan ili negativan). Nagib ST segmenta ima najveći prosječni utjecaj na predikcije modela. Njen doprinos iznosi oko 0.14, što ukazuje na značajan utjecaj na izlaz modela. Vrsta boli u prsima je druga najutjecajnija značajka, s prosječnim doprinosom od 0.11 na predikcije modela. Prisutnost ili odsutnost angine izazvane vježbanjem također značajno doprinosi, s prosječnim utjecajem od 0.11. Razina šećera u krvi natašte ima prosječni utjecaj od 0.06, što je čini umjereno važnom značajkom. Ostale značajke imaju umjeren do minimalan utjecaj na predikciju modela.

Slika 9 prikazuje SHAP grafikon koji vizualizira utjecaj svake značajke na izlaz modela kroz više instanci. X-os na kojoj se nalaze SHAP vrijednosti prikazuje utjecaj svake značajke na predikciju modela. Pozitivna SHAP vrijednost znači da značajka povećava vjerojatnost srčane bolesti, dok negativna SHAP vrijednost znači obrnuto. Na Y-osi su značajke poredane po važnosti, odnosno prosječnoj veličini SHAP vrijednosti, silaznim redoslijedom. Boja predstavlja vrijednost značajke. Crvena označava visoke vrijednosti značajki, dok plava označava niske vrijednosti. Kodiranje bojama pomaže razumjeti kako visoke ili niske vrijednosti svake značajke utječu na predikciju prema srčanoj bolesti (pozitivna SHAP vrijednost) ili ne-srčanoj bolesti (negativna SHAP vrijednost). Nagib ST segmenta ima najveći utjecaj na predikcije modela. Visoke vrijednosti (crvena) povećavaju vjerojatnost srčane bolesti, dok niske vrijednosti (plava) smanjuju vjerojatnost. Određene vrijednosti vrste boli u prsima (više vrijednosti u crvenoj) usmjeravaju predikciju prema srčanoj bolesti, dok druge vrijednosti (niže vrijednosti u plavoj) us-

mjeravaju prema ne-srčanoj bolesti. Angina izazvana vježbanjem također ima značajan utjecaj. Visoke razine šećera u krvi usmjeravaju predikciju prema srčanoj bolesti, dok niske razine usmjeravaju prema ne-srčanoj bolesti.

U SHAP force plotu (Slika 10), osnovna vrijednost, također poznata kao očekivana vrijednost, je prosječna predikcija modela preko skupa podataka za uvježbavanje. Služi kao početna točka za objašnjavanje pojedinačne predikcije određene podatkovne točke. U ovom slučaju osnovna vrijednost iznosi otprilike 0.5012. Model predviđa niži rizik od srčane bolesti ( $f(x) = 0.26$ ). Najutjecajniji faktori koji smanjuju rizik su odsutnost ExerciseAngina, ženski spol ( $\text{Sex} = 0$ ), ChestPainType, niska razina FastingBS, visoki MaxHr i mlađa starosna skupina (Age-Group). RestingECG rezultat i ST\_Slope su značajke koje doprinose povećanju rizika, ali su njihovi efekti nadmašeni drugim faktorima koji vode do niže ukupne predikcije rizika.

## 6 Zaključak

U ovom radu obrađeno je predviđanje bolesti srca algoritima strojnog učenja koristeći skup podataka sa Kaggle-a. Podaci su pripremljeni za rad te implementirati u dva modela strojnog učenja. Modeli su evaluirani uporabom metrika „Accuracy“ i „F1 Score“. Bolje performanse je pokazao model konvolucijske neuronske mreže. Uspoređujući rezultate ovog rada sa pregledom istraženosti područja dobiveni rezultati su približni, odnosno u skladu su sa ostalim radovima te ne odskaku. SHAP i LIME grafikonima je pružen uvid u to kako različite značajke doprinose predikciji modela. Budući rad ostavlja mjesta za poboljšanje i optimizaciju implementiranih algoritama i rad na većem skupu podataka.

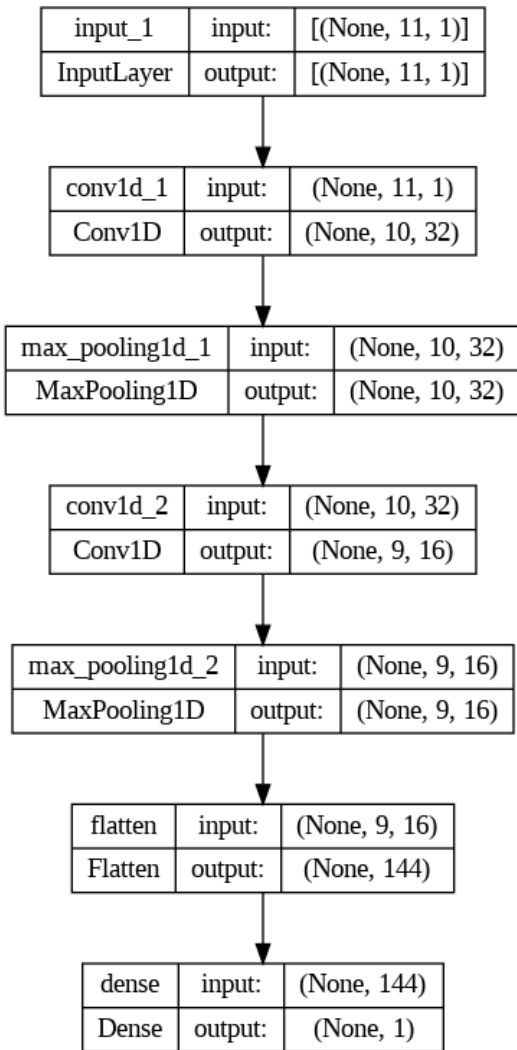
## Literatura

- [1] Mana Saleh Al Reshan, Samina Amin, Muhammad Ali Zeb, Adel Sulaiman, Hani Alshahrani, and Asadullah Shaikh. A robust heart disease

prediction system using hybrid deep neural networks. *IEEE Access*, 2023.

- [2] Nasser Allheeb, Summrina Kanwal, and Sultan Alamri. An intelligent heart disease prediction framework using machine learning and deep learning techniques. *International Journal of Data Warehousing and Mining (IJDWM)*, 19(1):1–24, 2023.
- [3] Laith Alzubaidi, Jinglan Zhang, Amjad J Humaidi, Ayad Al-Dujaili, Ye Duan, Omran Al-Shamma, José Santamaría, Mohammed A Fadhel, Muthana Al-Amidie, and Laith Farhan. Review of deep learning: concepts, cnn architectures, challenges, applications, future directions. *Journal of big Data*, 8:1–74, 2021.
- [4] Nadikatla Chandrasekhar and Samineni Peddakrishna. Enhancing heart disease prediction accuracy through machine learning techniques and optimization. *Processes*, 11(4):1210, 2023.
- [5] Cătălina-Lucia Cocianu, Cristian Răzvan Uscatu, Konstantinos Kofidis, Sorin Muraru, and Alin Gabriel Văduva. Classical, evolutionary, and deep learning approaches of automated heart disease prediction: A case study. *Electronics*, 12(7):1663, 2023.
- [6] Ruhi Fatima, Sabeena Kazi, Asifa Tassaddiq, Nilofer Farhat, Humera Naaz, and Sumera Jabbeen. Stacking ensemble machine learning algorithm with an application to heart disease prediction. *Contemporary Mathematics*, pages 905–925, 2023.
- [7] Alex Gramegna and Paolo Giudici. Shap and lime: an evaluation of discriminative power in credit risk. *Frontiers in Artificial Intelligence*, 4:752558, 2021.
- [8] Ahmad Hammoud, Ayman Karaki, Reza Tafreshi, Shameel Abdulla, and MF Wahid. Coronary heart disease prediction: a comparative study of machine learning algorithms. *J Adv Inf Technol*, 15:27–32, 2024.

- [9] Mahmudul Hasan, Md Abdus Sahid, Md Palash Uddin, Md Abu Marjan, Seifedine Kadry, and Jungeun Kim. Performance discrepancy mitigation in heart disease prediction for multisensory inter-datasets. *PeerJ Computer Science*, 10:e1917, 2024.
- [10] Mohammad Hossin and Md Nasir Sulaiman. A review on evaluation metrics for data classification evaluations. *International journal of data mining & knowledge management process*, 5(2):1, 2015.
- [11] Ramdas Kapila, Thirumalaisamy Ragunathan, Sumalatha Saleti, T Jaya Lakshmi, and Mohd Wazih Ahmad. Heart disease prediction using novel quine mccluskey binary classifier (qmbc). *IEEE Access*, 2023.
- [12] Ankit Kumar, Kamred Udham Singh, and Manish Kumar. A clinical data analysis based diagnostic systems for heart disease prediction using ensemble method. *Big Data Mining and Analytics*, 6(4):513–525, 2023.
- [13] Ahmed Haitham Najim and Nejeh Nasri. Artificial intelligence for heart disease prediction and imputation of missing data in cardiovascular datasets. *Cogent Engineering*, 11(1):2325635, 2024.
- [14] Azam Mehmood Qadri, Ali Raza, Kashif Munir, and Mubarak S Almutairi. Effective feature engineering technique for heart disease prediction with machine learning. *IEEE Access*, 11:56214–56224, 2023.
- [15] Atta Ur Rahman, Yousef Alsenani, Adeel Zafar, Kalim Ullah, Khaled Rabie, and Thokozani Shongwe. Enhancing heart disease prediction using a self-attention-based transformer model. *Scientific Reports*, 14(1):514, 2024.
- [16] Kumar Rethik, Arun Singh, Dalwinder Singh, and Manik Rakhra. Comparative analysis of different heart disease prediction models. In *2023 International Conference on Intelligent and Innovative Technologies in Computing, Electrical and Electronics (IITCEE)*, pages 992–996. IEEE, 2023.
- [17] Federico Soriano. Heart failure prediction, 2024. Accessed: 2024-06-16.
- [18] World Health Organization. Cardiovascular diseases (cvds), 2024. Accessed: 2024-06-13.



Slika 2: Arhitektura korištene konvolucijske neuronske mreže

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	<b>Sensitivity</b> $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	<b>Specificity</b> $\frac{TN}{(TN + FP)}$
		<b>Precision</b> $\frac{TP}{(TP + FP)}$	<b>Negative Predictive Value</b> $\frac{TN}{(TN + FN)}$	<b>Accuracy</b> $\frac{TP + TN}{(TP + TN + FP + FN)}$

Slika 3: Evaluacijske metrike

	precision	recall	f1-score	support
0	0.79	0.87	0.83	107
1	0.91	0.86	0.88	169
accuracy			0.86	276
macro avg	0.85	0.86	0.86	276
weighted avg	0.87	0.86	0.86	276

Slika 4: Classification report - LR


	precision	recall	f1-score	support
0	0.81	0.87	0.84	107
1	0.91	0.87	0.89	169
accuracy			0.87	276
macro avg	0.86	0.87	0.86	276
weighted avg	0.87	0.87	0.87	276

Slika 5: Classification report - CNN

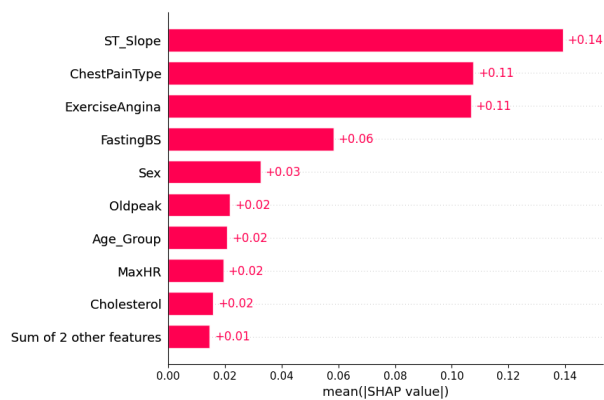





Slika 6: LIME plot



Slika 7: SHAP waterfall plot



Slika 8: SHAP bar plot



Slika 9: SHAP beeswarm plot



Slika 10: SHAP force plot

REF	SKUP PODATAKA	MODELI	ACCURACY	F1 SCORE
[12]	1) Heart disease dataset 2) CHD dataset	SVM, LR	1) 82% (LR) 2) 72.6% (LR)	N/A
[1]	1) Cleveland heart disease dataset 2) HD dataset (Switzerland + Cleveland + Statlog + Hungarian + Long Beach VA)	ANN, LSTM, CNN, Hybrid CNN-LSTM	1) 97.75% (CNN-LSTM) 2) 98.86% (CNN-LSTM)	1) 97.18% (CNN-LSTM) 2) 99.83% (CNN-LSTM)
[2]	1) UCI dataset 2) IEEE Dataport heart disease dataset	SVM Linear, MLP, SVM Polynomial, LR, SVM RBF, DNN, CNN, BLSTM	1) N/A 2) 98% (MLP)	1) N/A 2) 97% (SVM Linear, MLP)
[13]	1) Heart Attack Analysis and Prediction Dataset 2) Z-Alizadeh Sani dataset	DT, LDA, LR, NB, SVM, KNN, ENSEMBLE, ELM (100 hidden neurons), ELM (200 hidden neurons)	1) 97.58% (ELM 200 hidden neurons) 2) 99.061% (ELM 200 hidden neurons)	N/A
[6]	1) Heart disease dataset	LR, KNN, LDA, Nsvc, MLP, SEMLA	1) 97.28% (SEMLA)	1) 97.3% (SEMLA)
[14]	1) Heart disease dataset	LR, DT, RF, SVM, XGB, NB, KNN, GB, MLP	1) 100% (RF, DT)	2) 100% (RF, DT)
[5]	1) Cleveland dataset 2) Cleveland + Statlog dataset	LR, RF, KNN, soft-margin SVM, 2MES-SVM, CNN, LSTM, TPE-LSTM	N/A	1) 89.2% (2MES-SVM) 2) 88.9% (TPE-LSTM)
[11]	1) Cleveland dataset 2) HD dataset (Switzerland + Cleveland + Statlog + Hungarian + Long Beach VA) 3) Cardiovascular Disease Dataset	LR, DT, RF, KNN, NB, SVC, MLP, VC, QMBC	1) 98.36% (QMBC) 2) 98.73% (MLP) 3) 99.92% (QMBC)	1) 98.59% (QMBC) 2) 98.8% (MLP) 3) 99.92% (QMBC)
[8]	1) Hungarian + Cleveland + Statlog dataset	LR, KNN, SVC, RF, DT, NB, GB	1) 94.96% (RF)	N/A
[9]	1) Cleveland, Hungarian, Statlog, Switzerland, Long Beach VA	SVM, RF, MLP, LR, GNB, KNN, XGB, DT	1) 100% (RF)	1) 100% (RF)
[4]	1) Cleveland dataset 2) IEEE Dataport heart disease dataset	RF, KNN, LR, NB, GB, AB, SVE	1) 93.44% (SVE) 2) 95% (SVE)	N/A
[15]	1) Cleveland dataset 2) Cardiovascular Disease Dataset	CNN, RNN, RNN+, RETAIN, Dipole, Proposed model	1) 96.5% (Proposed) 2) 95.2% (Proposed)	N/A

Tablica 1: Pregled istraženosti područja

	<b>Značajka</b>	<b>Semantika</b>	<b>Vrijednost</b>
1	Age	Godine pacijenta	Numerička vrijednost
2	Sex	Spol pacijenta	M: muško, F: žensko
3	ChestPainType	Vrsta boli u prsima	TA: Typical Angina, ATA: Atypical Angina, NAP: Non-Anginal Pain, ASY: Asymptomatic
4	RestingBP	Krvni tlak u mirovanju	Numerička vrijednost mjerena u mmHg
5	Cholesterol	Kolesterol u serumu	Numerička vrijednost mjerena u mg/dl
6	FastingBS	Šećer u krvi natašte	1: ako je FastingBS > 120 mg/dl, 0: inače
7	RestingECG	Rezultati elektrokardiograma u mirovanju	Normal: normalno, ST: abnormalnost ST-T vala, LVH: vjerojatna ili definitivna hipertrofija lijeve klijetke
8	MaxHR	Postignut maksimalni broj otkucaja srca	Numerička vrijednost između 50 i 202
9	ExerciseAngina	Angina izazvana vježbanjem	Y: da, N: ne
10	Oldpeak	ST	Numerička vrijednost mjerena u depresiji
11	ST_slope	Nagib ST segmenta	Up: uzlazno, Flat: ravno, Down: silazno
12	HeartDisease	Izlazna klasa	1: srčana bolest, 0: normalno

Tablica 2: Opis značajki skupa podataka

<b>Age</b>	<b>Age Group</b>	<b>Age Group Code</b>
$20 \leq \text{Age} < 40$	20 - 40	0
$40 \leq \text{Age} < 60$	40 - 60	1
$60 \leq \text{Age} < 80$	60 - 80	2

Tablica 3: Kategorizacija varijable "Age"

Rad	LR		CNN	
	Accuracy	F1 Score	Accuracy	F1 Score
[12]	82%	/	/	/
[1]	/	/	96.86%	97.22%
[2]	95%	93%	59%	57%
[13]	81.8%	/	/	/
[6]	89.11%	89.1%	/	/
[14]	87%	87%	/	/
[5]	/	75.7%	/	83.6%
[11]	99.79%	99.79%	/	/
[8]	87.39%	/	/	/
[9]	99%	99%	/	/
[4]	89%	90%	/	/
[15]	/	/	74.7%	/
Predloženi rad	86%	88%	87%	87%

Tablica 4: Usporedba performansi modela sa srodnim radovima